

Alumno: Alderete Tomás

Parcial de Aprendizaje Automático Entrega 1

Entrega 1: Descripción y Formulación del Objetivo

Apertura: lunes 18 de mayo de 2026

Cierre: lunes 25 de mayo de 2026

- En esta primera entrega, debe proporcionar una descripción detallada de su proyecto de Aprendizaje Automático.
- Formule claramente el objetivo (General y Específicos) de su trabajo, indicando qué problema específico de su interés abordará con el modelo.
- Proporcione detalles sobre el contexto en el que se encuentra el problema y por qué es relevante.
- Defina claramente si el problema se trata de una clasificación o de regresión.
- Identifique que modelos podría utilizar.
- Esta entrega se debe hacer en un archivo .PDF

Dataset: Pacientes Egipcios con el virus de Hepatitis C

Link de Dataset:

<https://archive.ics.uci.edu/dataset/503/hepatitis+c+virus+hcv+for+egyptian+patients>

Información del dataset:

Este dataset proviene de una de las páginas recomendadas por los profesores de la materia, en la misma encontramos la siguiente información de pacientes con Hepatitis C, para mi parcial identifico que voy a utilizar un modelo de aprendizaje automático, es decir, reconocer patrones, realizar predicciones y en base a ello llegar a una conclusión.

Columnas:

Edad (Int64): 32 a 61

Género (Int64):

1 = Hombre

2 = Mujer

IMC (Int64): 18 a 50

Fiebre (Int64):

- 1 = Ausente
- 2 = Presente

Vómitos (Int64):

- 1 = Ausente
- 2 = Presente

Dolor de Cabeza (Int64):

- 1 = Ausente
- 2 = Presente

Diarrea (Int64):

- 1 = Ausente
- 2 = Presente

Fatiga (Int64):

- 1 = Ausente
- 2 = Presente

Dolor de huesos (Int64):

- 1 = Ausente
- 2 = Presente

Ictericia (Int64):

- 1 = Ausente
- 2 = Presente

Dolor epigástrico (Int64):

- 1 = Ausente
- 2 = Presente

Glóbulos blancos (Int64): 0 a 12101

Glóbulos rojos (float64): 0 a 5018451

Hemoglobina (Int64): 14 a 20

Plaquetas (float64): 93013 a 226464

AST1 (Int64): 0 a 128

ALT1 (Int64): 0 a 12

ALT4 (float64): 0 a 12

ALT12 (Int64): 0 a 12

ALT24 (Int64): 0 a 12

ALT36 (Int64): 0 a 12

ALT48 (Int64): 0 a 12

RNA Base (Int64): 0 a 1201086

RNA 4 (Int64): 0 a 1201715

RNA 12 (Int64): 0 a 3731527

RNA EOT (Int64): 0 a 808450

RNA EF (Int64): 0 a 808450

Calificación histórica de referencia (Int64): 1 a 16

Calificación histórica (Int64): 1 al 4

Correcciones:

Lo primero a realizar es cambiar el tipo de dato de las columnas, me gustaría trabajar con valores booleanos donde corresponde, cambiar el valor entero de “1 y 2” por el valor bool de “0 y 1”

Luego buscar y limpiar los datos ya que hay valores con decimales, en dado caso reducirlos a máximo 2 decimales

Algo a destacar muy positivo es que no hay nulos en la base de datos y es algo que no requiere trabajo

Objetivo:

El problema se trata de una clasificación ya que en mi caso busco que la respuesta sea “Si o No”

En cuanto al objetivo principal, va a ser crear un modelo de aprendizaje automático que pueda predecir si un paciente con Hepatitis C tiene Dolores de cabeza o huesos, en base a la información de las otras columnas, para ello me voy a apoyar sobre todo en las columnas con síntomas.

Objetivo Secundario:

Las columnas AST, ALT y RNA son el avance de la hepatitis, contienen valores muy bajos si el paciente se curó o contiene valores muy altos si sigue en tratamiento. Voy a intentar utilizar esta información para crear otro modelo de aprendizaje que pueda detectar si un paciente tiene o no Hepatitis C, sin embargo, considero que es todo un reto y quiero proponérmelo para este parcial.

Objetivo Secundario 2:

También podría proponerme el estudiar los valores por semanas tratando de predecir si un paciente tiene Hepatitis luego de la 3er semana, teniendo en cuenta el estudio de las 2 primeras, y los síntomas

Conclusión:

Considero que para estos objetivos voy a utilizar el árbol de decisión ya que los valores entre las variables son mayormente booleanos, también considere la posibilidad de utilizar KNN para el objetivo secundario 2 y sería interesante ya que los valores son muy extremos y podemos identificar bien que entre un valor como 5 o 10 es de un paciente recuperado y valores como 10.000.000 un número extremadamente alejado, es un paciente aún en tratamiento

Voy a utilizar KNN, el árbol de decisión y me gustaría observar los resultados o pensar en poder integrar los nuevos modelos de predicción, hasta el momento no se me ocurrió donde pueden destacar.

Información aparte:

Para esta actividad encontré muchos dataset interesantes en kaggle, sé que son de datos inventados, no me quedó muy claro si era posible o no.

Cerrando la idea quería mencionar algunos que me llamaron la atención para el parcial. En uno se menciona el uso de IA en alumnos de diferentes carreras, tomando en cuenta su rendimiento académico a lo largo del tiempo, su estrés, la nota del examen final y en este dataset se intenta ver a la IA como una herramienta “mala” para los estudiantes, sin embargo, en el mismo hay registros de alumnos excelentes que le dan un buen uso ya que existe esta columna, es decir “el uso que le dió el alumno a la IA”

Hablo de este dataset ya que se me dificultó mucho la búsqueda de datasets, la mayoría interesantes no eran posibles para un modelo de aprendizaje ya que tenían demasiados nulos, muy poca información, o eran inventados. Con esto quería llegar a proponer de recomendar más dataset como el de Tierra del Fuego, personalmente me llamó la atención sin embargo ya estaba tomado.