

Alumno: Alderete Tomás

Parcial de Aprendizaje Automático Entrega 2

Entrega 2: Descripción del Dataset y Origen

Apertura: lunes, 25 de mayo de 2026

Cierre: lunes 1 de junio de 2026

- En esta segunda entrega, debe tener acceso al dataset que utilizará en su proyecto de Aprendizaje Automático.
- Proporcione una descripción completa del dataset, incluyendo la cantidad de instancias, características (columnas), tipos de datos, y cualquier información relevante.
- Informe sobre el origen del dataset, es decir, de dónde provienen los datos. Esto puede incluir la fuente, la fecha de adquisición y cualquier proceso de recopilación o preprocesamiento que haya realizado.
- Se recomienda utilizar dataset de dominio público (ipiec, datos.gob.ar, etc).
- Esta entrega debe ser realizada en el repositorio GIT, incluyendo archivos de dataset y documentos.

Dataset: Pacientes Egipcios con el virus de Hepatitis C

Link de Dataset:

<https://archive.ics.uci.edu/dataset/503/hepatitis+c+virus+hcv+for+egyptian+patients>

Nombre del archivo:

HCV-Egy-Data.csv

Información del dataset:

Este dataset proviene de una de las páginas recomendadas por los profesores de la materia, en la misma encontramos la información de pacientes egipcios que se sometieron a tratamientos con dosis para la VHC durante aproximadamente 18 meses.

Fuente: archive.ics.uci.edu (UC Irvine Machine Learning Repository)

Dataset publicado el día: 29/9/2019

Fecha de Adquisición: 25 de Mayo de 2026

Área: Salud y Medicina

Creadores del Dataset:

Sanaa Kamal

Mohamed ElEleimy

Doaa Hegazy

Mahmoud Nasr

Cantidad de Registros / Instancias: 1385 registros

Cantidad de Columnas: 28

Datos Faltantes en el Dataset: No

Información de Columnas:

Edad (Int64): 32 a 61

Género (Int64):

1 = Hombre

2 = Mujer

IMC (Int64): 18 a 50

Fiebre (Int64):

1 = Ausente

2 = Presente

Vómitos (Int64):

1 = Ausente

2 = Presente

Dolor de Cabeza (Int64):

1 = Ausente

2 = Presente

Diarrea (Int64):

1 = Ausente

2 = Presente

Fatiga (Int64):

1 = Ausente

2 = Presente

Dolor de huesos (Int64):

1 = Ausente

2 = Presente

Ictericia (Int64):

1 = Ausente

2 = Presente

Dolor epigástrico (Int64):

1 = Ausente

2 = Presente

Glóbulos blancos (Int64): 0 a 12101

Glóbulos rojos (float64): 0 a 5018451

Hemoglobina (Int64): 14 a 20

Plaquetas (float64): 93013 a 226464

AST1 (Int64): 0 a 128

ALT1 (Int64): 0 a 12

ALT4 (float64): 0 a 12

ALT12 (Int64): 0 a 12

ALT24 (Int64): 0 a 12

ALT36 (Int64): 0 a 12

ALT48 (Int64): 0 a 12

RNA Base (Int64): 0 a 1201086

RNA 4 (Int64): 0 a 1201715

RNA 12 (Int64): 0 a 3731527

RNA EOT (Int64): 0 a 808450

RNA EF (Int64): 0 a 808450

Calificación histórica de referencia (Int64): 1 a 16

Calificación histórica (Int64): 1 al 4

Correcciones:

Lo primero a realizar es cambiar el tipo de dato de las columnas, me gustaría trabajar con valores booleanos donde corresponde, cambiar el valor entero de “1 y 2” por el valor bool de “0 y 1”

Luego buscar y limpiar los datos ya que hay valores con decimales, en dado caso reducirlos a máximo 2 decimales

GITHUB:

https://github.com/AldereteTomas1/Tecnicatura/tree/main/Aprendizaje_Automatico/Parcial

COLAB:

https://colab.research.google.com/drive/1s44aQ6Rk4I_oRwK6-kJfeqT90xvVvpO8#scrollTo=lFYU5xD5sbne