Tareas a Realizar

1. Identificación de Tipos de Datos

- Clasifica cada columna según su tipo (numérico, categórico, ordinal, fecha) y explica cómo se debería manejar cada una.

2. Limpieza de Datos

- `Detecta y corrige valores faltantes en las columnas necesarias.`
- `Identifica y elimina valores atípicos en la columna “Salario”.`
- `Corrige inconsistencias en los datos categóricos (ejemplo: "Licenciado" y "li`

3. Transformación de Datos

- `Convierte las variables categóricas en numéricas utilizando codificación ordi`
- `Aplica normalización al salario para facilitar comparaciones.`
- `Crea una nueva variable “Años hasta jubilación” suponiendo que la edad de ret`

4. Análisis Exploratorio con LLM

Usa ChatGPT o una herramienta LLM para ayudarte en alguna de estas tareas:

- `Generar un resumen de los datos.`
- `Explicar cómo manejar valores faltantes.`
- `Sugerir formas de visualizar los datos.`

Ejemplo de consulta a ChatGPT:

"Tengo un dataset con sueldos y edades, ¿cómo puedo detectar y eliminar outliers en Python?"

Comparte en el foro la consulta que hiciste y la respuesta que te dio el LLM.

```
import pandas as pd
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder

# Cargar los datos
```

```
df = pd.DataFrame({
"ID": [1, 2, 3, 4, 5],
"Nombre": ["Juan", "María", "Pedro", "Ana", "Luis"],
"Edad": [32, -28, 40, 35, 50],
"Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Docto
"Salario": [50000, 60000, None, 55000, 200000],
"Categoría": ["Junior", "Senior", "Senior", "Junior", "Manager"],
"Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

# 1 Corrección de edad negativa
df["Edad"] = df["Edad"].abs()

# 2 Imputación del salario faltante con la mediana
df["Salario"].fillna(df["Salario"].median(), inplace=True)

# 3 Detectar y eliminar valores atípicos con IQR
Q1, Q3 = df["Salario"].quantile([0.25, 0.75])
IQR = Q3 - Q1
df = df[~((df["Salario"] < (Q1 - 1.5 * IQR)) | (df["Salario"] > (Q3 + 1.5 * IQR)

# 4 Codificación ordinal para "Nivel Educativo"
encoder_ordinal = OrdinalEncoder(categories=[["Licenciado", "Ingeniero", "Doctor
df["Nivel_Cod"] = encoder_ordinal.fit_transform(df[["Nivel_Educativo"]])

# 5 Normalización del salario
scaler = MinMaxScaler()
df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

# 6 Creación de nueva variable "Años hasta jubilación"
df["Años_Hasta_Jubilación"] = 65 - df["Edad"]
print(df)
```

```
   ID Nombre  Edad Nivel_Educativo  Salario Categoría    Estado  Nivel_Cod  \
0   1   Juan    32      Licenciado  50000.0    Junior    Activo        0.0
1   2  María    28       Ingeniero  60000.0    Senior    ACTIVO        1.0
2   3  Pedro    40       Doctorado  57500.0    Senior  Inactivo        2.0
3   4    Ana    35      Licenciado  55000.0    Junior    Activo        0.0

   Salario_Normalizado  Años_Hasta_Jubilación
0                 0.00                     33
1                 1.00                     37
2                 0.75                     25
3                 0.50                     30
/tmp/ipykernel_6745/2802220023.py:19: FutureWarning: A value is trying to be se
The behavior will change in pandas 3.0. This inplace method will never work bec

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.me


  df["Salario"].fillna(df["Salario"].median(), inplace=True)
```

```
# 1 - Identificación de tipos de datos.
print(df.dtypes)
print("\n") #Baja

# Cambio el tipo de dato de "Categoria"
```

```
df["Categoría"] = df["Categoría"].astype("category")

# Cambio el tipo de dato de "Nivel de Educación"
df["Nivel_Educativo"] = df["Nivel_Educativo"].astype("category")

# Cambio el tipo de dato de "Estado" a Objeto
df["Estado"] = df["Estado"].astype("object")

# Compruebo los cambios realizados
print("\n") #bajo un renglon
print(df.dtypes)


# Clasifico los tipos de datos
dato_numerico = list(df.select_dtypes(include=['int64', 'float64']).columns)
dato_fecha = list(df.select_dtypes(include=['datetime64']).columns)
dato_categorico = list(df.select_dtypes(include=['object', 'category']).column
dato_ordinal = list(df.select_dtypes(include=['category']).columns)


#Utilice ayuda de la IA para separar los elementos de las listas ordinales y c
dato_categorico = [x for x in dato_categorico if x not in dato_ordinal]


#Por ultimo muestro todas las listas
print("\n") #bajo un renglon
print("Los datos numéricos son: ", dato_numerico)
print("Los datos categóricos son: ", dato_categorico)
print("Los datos ordinales son: ", dato_ordinal)
print("Los datos tipo fecha son: ", dato_fecha)
```

```
ID                        int64
Nombre                   object
Edad                      int64
Nivel_Educativo          object
Salario                 float64
Categoría                object
Estado                   object
Nivel_Cod               float64
Salario_Normalizado     float64
Años_Hasta_Jubilación     int64
dtype: object




ID                         int64
Nombre                    object
Edad                       int64
Nivel_Educativo         category
Salario                  float64
Categoría               category
Estado                    object
Nivel_Cod                 float64
Salario_Normalizado       float64
Años_Hasta_Jubilación       int64
dtype: object
```

```
Los datos numéricos son:  ['ID', 'Edad', 'Salario', 'Nivel_Cod', 'Salario_Norma
Los datos categóricos son:  ['Nombre', 'Estado']
Los datos ordinales son:  ['Nivel_Educativo', 'Categoría']
Los datos tipo fecha son:  []
```

Los tipos de datos numéricos pueden ser utilizados para modelos de predicción, se utilizan gráficos como histogramas, diagramas de dispersión, y boxplots.

Los tipos de datos categóricos no tienen un orden de jerarquía. En el caso de Estado podría observar con un Gráfico de Barras para poder comparar y a la vez separar los datos "Activos" de los "Inactivos". Otra opción son los gráficos de torta aunque personalmente es más sencillo de entender el de barras.

Por otro lado los tipos ordinales podemos transformarlos en números para luego estudiarlos. podríamos armar un boxplot en el cual busquemos la mediana o el promedio ya estos datos serían representativos en cuanto al nivel de jerarquía que presenten, otra opción puede ser un grafico de barras pero manteniendo el orden de la jerarquía

Y por ultimo la fecha, si bien, en este caso no encontramos datos que cumplan con esta condición se podría separar en 3 columnas de "dia, mes y año" y luego se podríamos utilizar esas columnas para estudiar los datos registrados en cierto periodo de tiempo, para ello podríamos usar gráficos de lineas, graficos de barras o mapas de calor.

```
# 2 - Limpieza de Datos
# Cambio el dato de "ACTIVO" por "Activo"
df['Estado'] = df['Estado'].str.capitalize()
df.head()
```

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Sal
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	María	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

Próximos pasos: Generar código con df | New interactive sheet

```
# 3 - Transformación de Datos
# Voy a considerar que "Nombre" no es una variable para estudiar con codificac
from sklearn.preprocessing import OrdinalEncoder
from sklearn.preprocessing import OneHotEncoder


# Defino el orden en Nivel Educativo y Categorias.
```

```
orden_nivel = [['Licenciado', 'Ingeniero', 'Doctorado']]
orden_categoria = [['Junior', 'Senior', 'Manager']]


# Luego aplico la codificación ordinal.
encoder_ordinal = OrdinalEncoder(categories=orden_nivel)
df['Nivel_Educativo_Cod'] = encoder_ordinal.fit_transform(df[['Nivel_Educativo

encoder_ordinal = OrdinalEncoder(categories=orden_categoria)
df['Categoría_Cod'] = encoder_ordinal.fit_transform(df[['Categoría']])

# Aplico OneHotEncoder a Estado.

encoder_onehot = OneHotEncoder(sparse_output=False, drop='first')
estado_encoded = encoder_onehot.fit_transform(df[['Estado']])
df[encoder_onehot.get_feature_names_out(['Estado'])] = estado_encoded

# Estandarización de salario.
Estandar_salario = df['Salario'].mean()
df['Salario_Estandarizado'] = df['Salario'] / Estandar_salario

# Nueva Variable, si es jubilado devuelve True, caso contrario False.
df['Es_Jubilado'] = df['Años_Hasta_Jubilación'] < 0


df.head()
```

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Sal
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	María	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

Próximos pasos: Generar código con df | New interactive sheet

Se puede ver que el salario estandarizado, aquellos valores que superan el 1 son mayores al promedio y los que están por debajo, significa que tienen un sueldo menor al promedio.

En la columna de "Es Jubilado" ya había una de "Años para la jubilación" pero cree esta columna ya que es más sencillo de visualizar

1. Relación principal: Edad vs Sueldo

👉 Gráfico de dispersión (scatter plot)

Eje X: Edad Eje Y: Sueldo Color: Categoría (Junior, Senior, Manager)

💡 Esto es CLAVE porque:

Ves si el sueldo crece con la edad Ves diferencias entre categorías al mismo tiempo

---

2. Sueldo según categoría

👉 Boxplot (diagrama de caja)

Eje X: Categoría Eje Y: Sueldo

💡 Te muestra:

Mediana de sueldo por grupo Variabilidad Outliers

👉 Ideal para responder: "¿Cuánto gana un Senior vs un Junior?"

---

3. Sueldo según nivel educativo

👉 Boxplot o gráfico de barras (promedio)

Eje X: Nivel educativo (Lic, Ing, Doc) Eje Y: Sueldo

💡 Te sirve para ver si estudiar más impacta en el sueldo.

---

4. Estado laboral

👉 Gráfico de barras

Conteo de Activos vs Inactivos

💡 Simple, pero útil para contexto.

En esta 1er visualización podemos ver un gráfico de disperción en donde se puede observar los datos en relación a la edad con el salario, pero a su vez el color indica la categoría en la que trabaja la persona. Con los pocos datos estudiados podemos observar que en los senior tienen un sueldo más elevado que los junior, y a su vez que la edad no es un indicador relevante a la hora de estudiar la categoría o el sueldo, encontramos los datos muy dispersos, en otras palabras la edad no es un factor a tener en cuenta.

En ka 2da visualización observamos lo mismo que en la anterior quitando el factor de la edad, podemos observar claramente como los senior se acercan a un sueldo de +56.000 mientras que los junior alcanzan como maximo 55.000 .

En el 3er grafico al igual que anteriores encontramos que en este se estudia el dinero pero desde el punto de vista del nivel educativo. Se puede observar que los ingenieros cobran mpas que aquellos con un doctorado o con una licenciatura, aunque con los pocos datos de la tabla, considero que puede no ser representativo a la realidad.

Por ultimo el gráfico de barras para estudiar la cantidad de profesionales Activos e Inactivos, vemos que los resultados son claramente que hay más Activos lo que indica algo positivo, pero como mencione en anteriores gráficos sería interesante estudiarlo con más datos.

```
import matplotlib.pyplot as plt
import seaborn as sns

# 1 - RELACIÓN EDAD Y SUELDO CON COLORES DE CATEGORÍA

plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='Edad', y='Salario', hue='Categoría', palette='viri
plt.title('Relación entre Edad y Salario por Categoría')
plt.xlabel('Edad')
plt.ylabel('Salario')
plt.grid(True, linestyle='--', alpha=0.7)
plt.legend(title='Categoría')
plt.tight_layout()
plt.show()
```

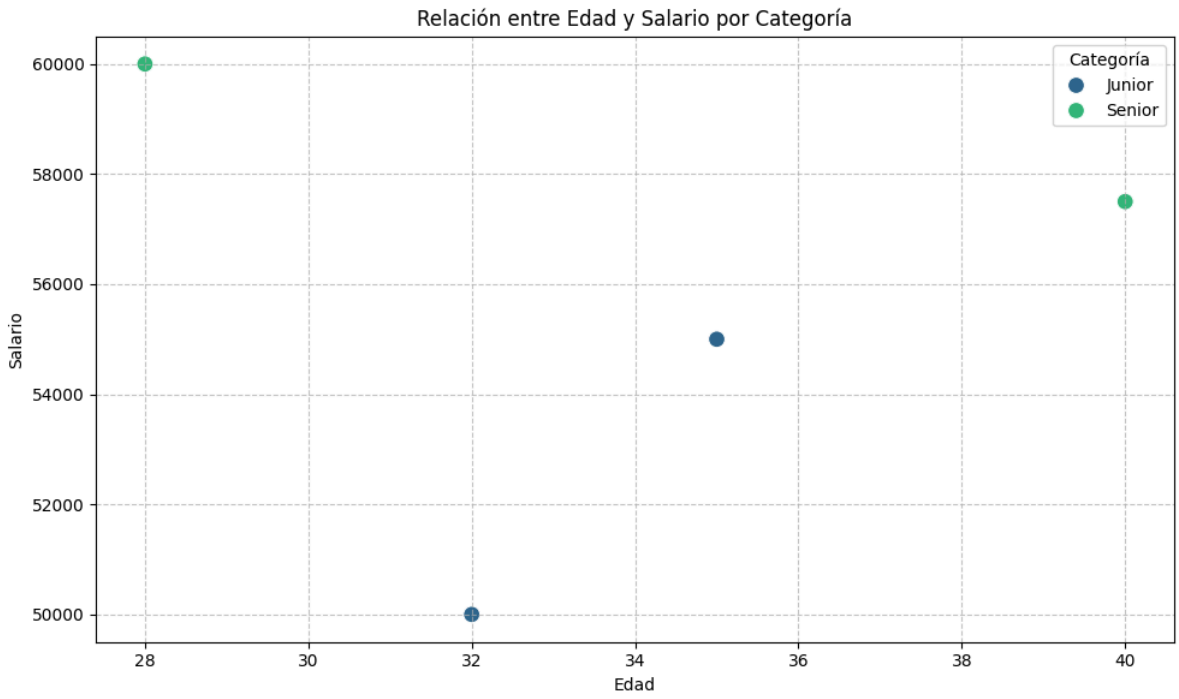


```
# 2 - SUELDO SEGÚN CATEGORÍA

plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='Categoría', y='Salario', palette='viridis')
```

```
/tmp/ipykernel_6745/1681261492.py:4: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v

  sns.boxplot(data=df, x='Categoría', y='Salario', palette='viridis')
<Axes: xlabel='Categoría', ylabel='Salario'>
```

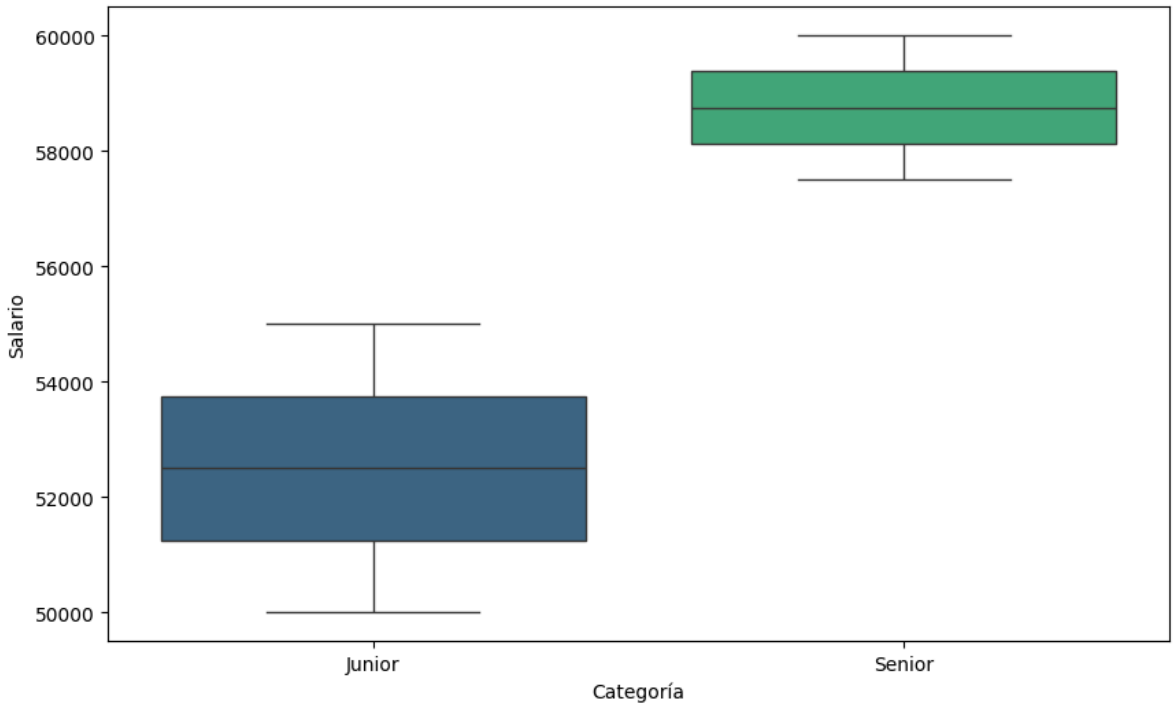


```
# 4 - SUELDO SEGÚN NIVEL EDUCATIVO

plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='Nivel_Educativo', y='Salario', palette='viridis')
```

```
/tmp/ipykernel_6745/945471195.py:4: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in

  sns.boxplot(data=df, x='Nivel_Educativo', y='Salario', palette='viridis')
<Axes: xlabel='Nivel_Educativo', ylabel='Salario'>
```

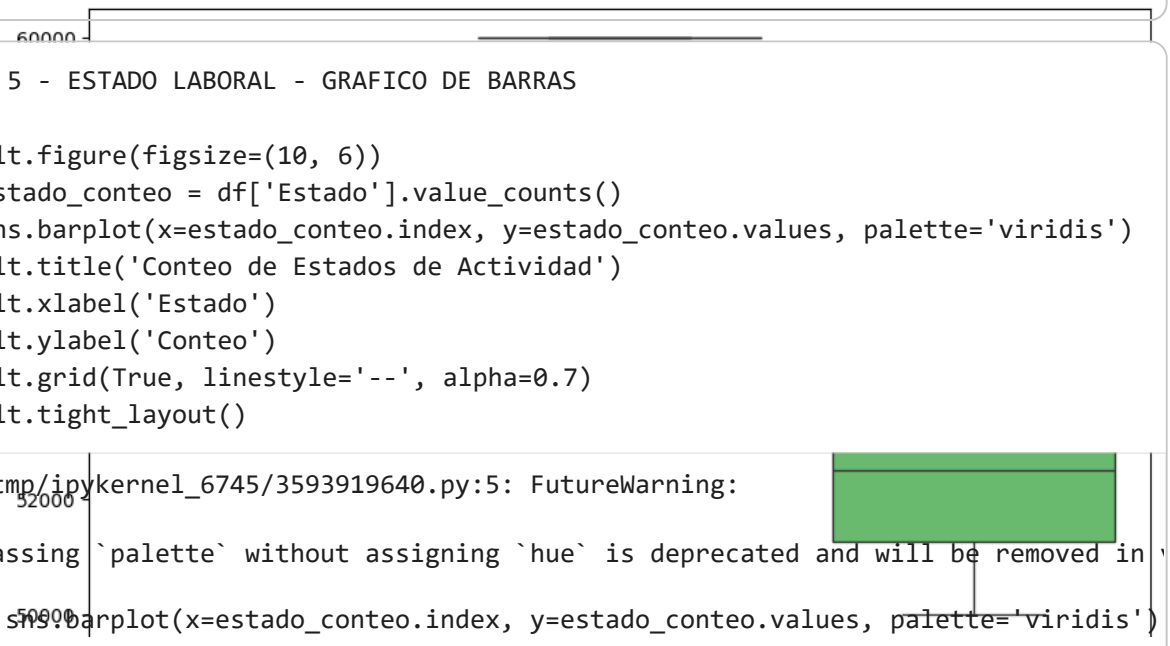


```
# 5 - ESTADO LABORAL - GRAFICO DE BARRAS

plt.figure(figsize=(10, 6))
estado_conteo = df['Estado'].value_counts()
sns.barplot(x=estado_conteo.index, y=estado_conteo.values, palette='viridis')
plt.title('Conteo de Estados de Actividad')
plt.xlabel('Estado')
plt.ylabel('Conteo')
plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
```
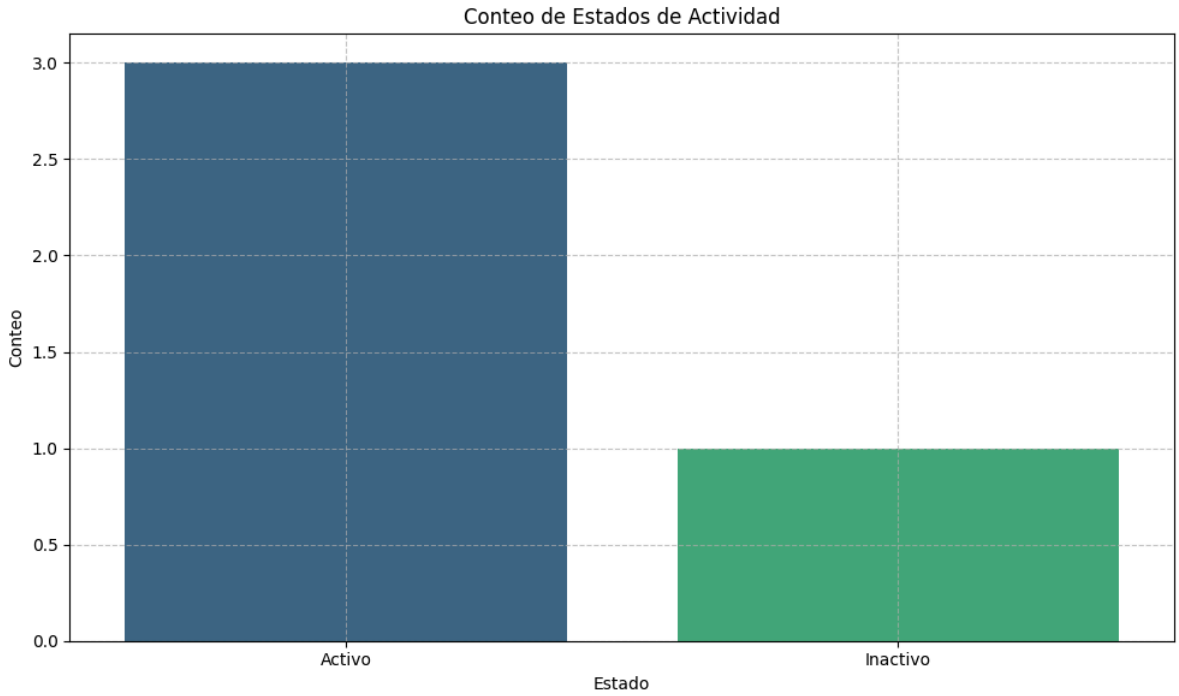
```
/tmp/ipykernel_6745/3593919640.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in

  sns.barplot(x=estado_conteo.index, y=estado_conteo.values, palette='viridis')
```